El Problema

"Imaginen un salón de clases en una zona rural, a 3 horas del pueblo más cercano. No hay señal de internet. No hay forma de acceder a ChatGPT, Gemini o Claude. La inteligencia artificial más avanzada del mundo no puede llegar hasta ellos porque depende de la nube, de servidores gigantes y de conexiones de banda ancha.

En **Neuro-Semilla**, nos preguntamos: ¿Y si pudiéramos llevar un tutor de IA inteligente, privado y sin internet a los dispositivos más baratos del planeta? Para lograrlo, teníamos que romper una regla de la IA moderna: **hacer que el modelo sea infinitamente más pequeño sin que pierda la capacidad de hablar**."

La Solución (Arquitectura BitNet 1.58b)

"Para resolver esto, no usamos un modelo tradicional. Construimos desde cero un **LLM (Large Language Model) basado en la arquitectura BitNet 1.58b**.

Mientras que modelos como GPT-4 usan 16 o 32 bits para cada uno de sus parámetros (lo que los hace pesar gigabytes), nosotros usamos **pesos ternarios**. ¿Qué significa esto? Que cada 'conexión neuronal' de nuestra IA solo puede valer tres cosas: **-1, 0 o +1**.

¿El resultado? Un modelo que reduce su tamaño drásticamente, que no necesita tarjetas gráficas caras para funcionar (porque elimina las multiplicaciones complejas en la inferencia) y que puede correr en un procesador común.

Pero no solo es teoria. **Lo hicimos realidad.** Entrenamos un modelo de 17 millones de parámetros usando Wikipedia en español, con un vocabulario personalizado de 8,192 palabras.

Tuvimos que corregir errores matemáticos complejos en el gradiente del ***Straight-Through Estimator*** (STE) y ajustar el Dropout para evitar que la IA colapsara por sobreajuste.

Hoy, ese modelo está vivo y responde preguntas."

Entonces lo convertimos en el corazón de nuestra idea, “UN NODO DE INTELIGENCIA ARTIFICIAL que enseña sin internet, con inferencia local real, un orquestador que decide qué tarea merece el modelo y un copiloto docente que se alimenta de las dudas reales del aula.

La Demo en Vivo

(Cambia a la pantalla de tu computadora mostrando Gradio, o reproduce el video de respaldo si el internet falla)

Tú:

"Y aquí está la prueba. Lo que ven en pantalla es nuestro modelo de 17M corriendo **al 100% de forma local en la CPU de esta laptop, sin internet**. No hay servidores de Google o Microsoft detrás.

Voy a pedirle que escriba un fragmento estilo Wikipedia..."

(Escribes el prompt: "La Revolución Francesa fue un" y bajas la temperatura a 0.7)

"Fíjense en cómo genera el texto de forma coherente, en español y sin alucinaciones graves. Es rápido, es privado, y es nuestro."

La Visión (El "Kicker" del Hackathon)

(Muestra una foto de un ESP32 o una Raspberry Pi con el logo de Neuro-Semilla)

Tú:

"Este modelo de 17M fue entrenado en la nube de Kaggle, pero su destino es el borde. Gracias a los pesos ternarios, este archivo se puede empaquetar a **menos de 500 Megabytes**.

Esto significa que Neuro-Semilla no se queda en la laptop. El siguiente paso de nuestro roadmap es portar este modelo a un microcontrolador **ESP32-S3** de 10 dólares, para que cualquier escuela sin luz o sin internet tenga un tutor de cuentos, historia o matemáticas en su bolsillo.

No estamos clonando modelos gigantes. Estamos sembrando la semilla de una IA democrática, eficiente y soberana. Muchas gracias."